2nd Meet

How was your week?

□ 오늘 공부할 것은

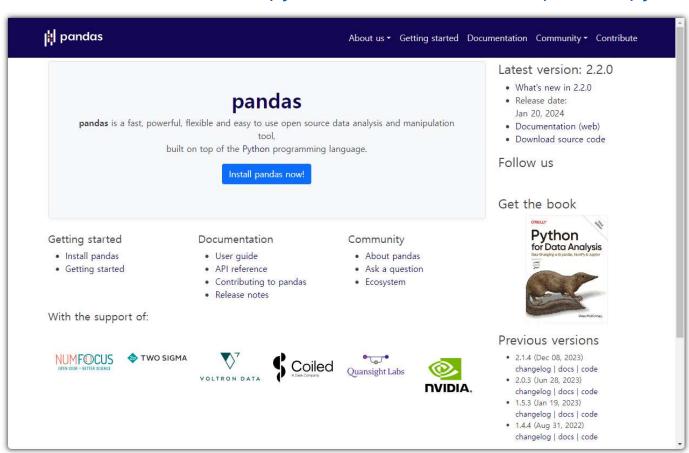
04. 데이터 핸들링 – 판다스	39
판다스 시작 - 파일을 DataFrame으로 로딩, 기본 API	40
DataFrame과 리스트, 딕셔너리, 넘파이 ndarray 상호 변환	49
DataFrame의 칼럼 데이터 세트 생성과 수정	53
DataFrame 데이터 삭제	55
Index 객체	58
데이터 셀렉션 및 필터링	62
정렬, Aggregation 함수, GroupBy 적용	73
결손 데이터 처리하기	77
apply lambda 식으로 데이터 가공	80

01. 사이킷런 소개와 특징	85
02. 첫 번째 머신러닝 만들어 보기 - 붓꽃 품종 예측하기	86
03. 사이킷런의 기반 프레임워크 익히기	91
Estimator 이해 및 fit(), predict() 메서드	91
사이킷런의 주요 모듈	92
내장된 예제 데이터 세트	94
04. Model Selection 모듈 소개	98
학습/테스트 데이터 세트 분리 - train_test_split()	98
교차 검증	100
GridSearchCV - 교차 검증과 최적 하이퍼 파라미터 튜닝을 한 번에	111

Now, It's your turn P.P.P.

□ pandas

- https://pandas.pydata.org/
- https://github.com/whatwant-school/python-ml/blob/main/02-pandas.ipynb



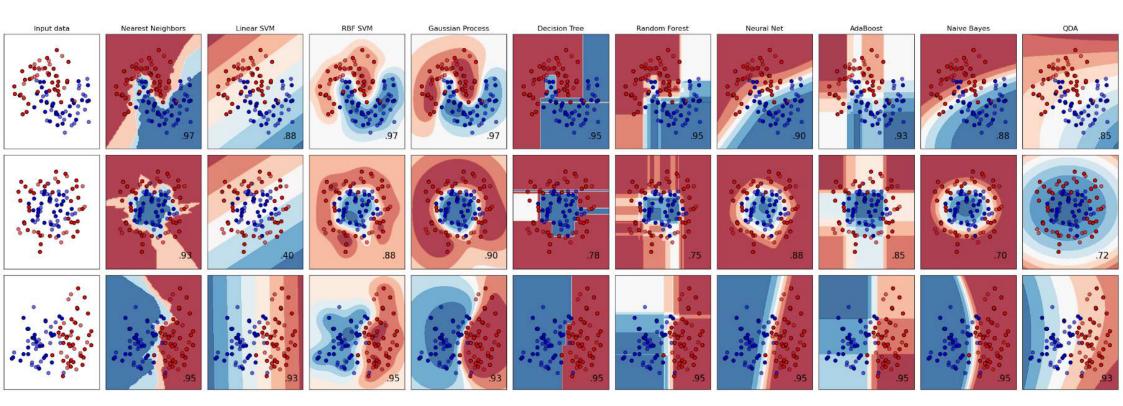
☐ scikit-learn

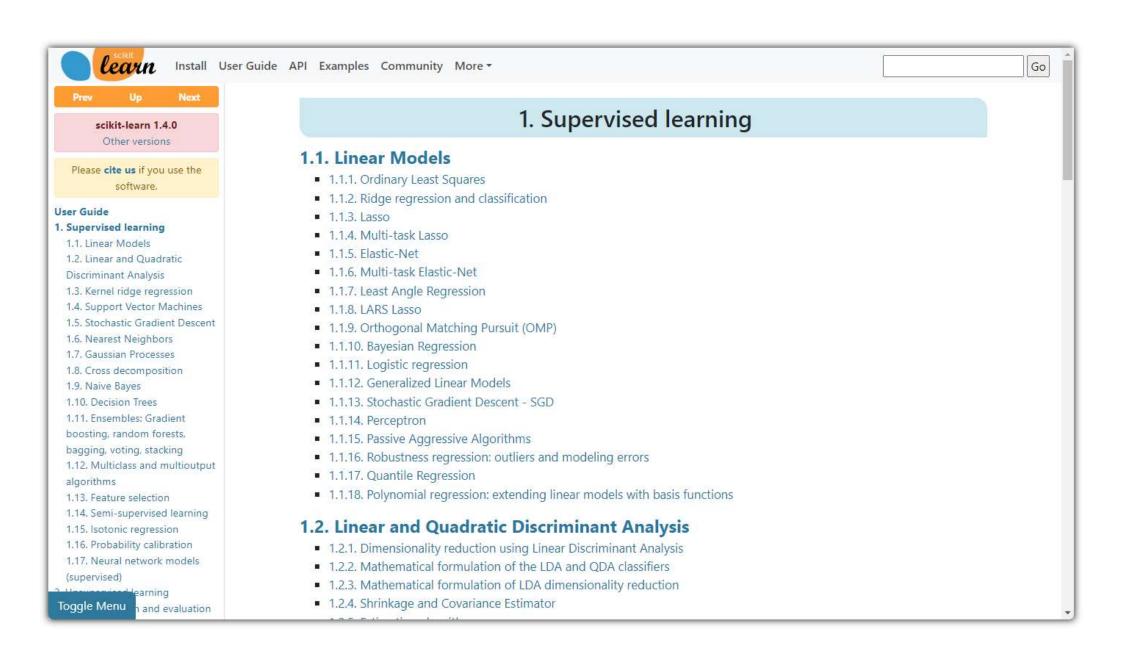
- https://scikit-learn.org/stable/

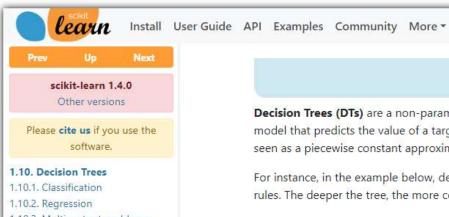


from matplotlib.colors import ListedColormap

Toggle Menu







1.10.3. Multi-output problems

1.10.4. Complexity

1.10.5. Tips on practical use

1.10.6. Tree algorithms: ID3, C4.5,

C5.0 and CART

1.10.7. Mathematical formulation

1.10.8, Missing Values Support

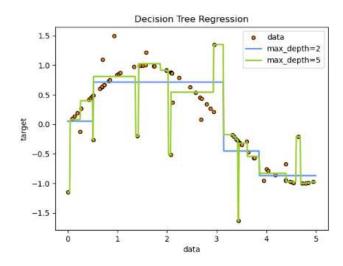
1.10.9. Minimal Cost-Complexity
Pruning

1.10. Decision Trees

Go

Decision Trees (DTs) are a non-parametric supervised learning method used for classification and regression. The goal is to create a model that predicts the value of a target variable by learning simple decision rules inferred from the data features. A tree can be seen as a piecewise constant approximation.

For instance, in the example below, decision trees learn from data to approximate a sine curve with a set of if-then-else decision rules. The deeper the tree, the more complex the decision rules and the fitter the model.



Some advantages of decision trees are:

- Simple to understand and to interpret. Trees can be visualized.
- Requires little data preparation. Other techniques often require data normalization, dummy variables need to be created and blank values to be removed. Some tree and algorithm combinations support missing values.

Toggle Menu

Install User Guide API Examples Community More *

Go

Prev

New

scikit-learn 1.4.0

Other versions

Please **cite us** if you use the software.

1.10. Decision Trees

- 1.10.1. Classification
- 1.10.2. Regression
- 1.10.3. Multi-output problems
- 1.10.4. Complexity
- 1.10.5. Tips on practical use
- 1.10.6. Tree algorithms: ID3, C4.5,
- C5.0 and CART
- 1.10.7. Mathematical formulation
- 1.10.8, Missing Values Support
- 1.10.9. Minimal Cost-Complexity
 Pruning

1.10.1. Classification

DecisionTreeClassifier is a class capable of performing multi-class classification on a dataset.

As with other classifiers, DecisionTreeClassifier takes as input two arrays: an array X, sparse or dense, of shape (n_samples, n_features) holding the training samples, and an array Y of integer values, shape (n_samples,), holding the class labels for the training samples:

```
>>> from sklearn import tree
>>> X = [[0, 0], [1, 1]]
>>> Y = [0, 1]
>>> clf = tree.DecisionTreeClassifier()
>>> clf = clf.fit(X, Y)
```

After being fitted, the model can then be used to predict the class of samples:

```
>>> clf.predict([[2., 2.]])
array([1])
```

In case that there are multiple classes with the same and highest probability, the classifier will predict the class with the lowest index amongst those classes.

As an alternative to outputting a specific class, the probability of each class can be predicted, which is the fraction of training samples of the class in a leaf:

```
>>> clf.predict_proba([[2., 2.]])
array([[0., 1.]])
```

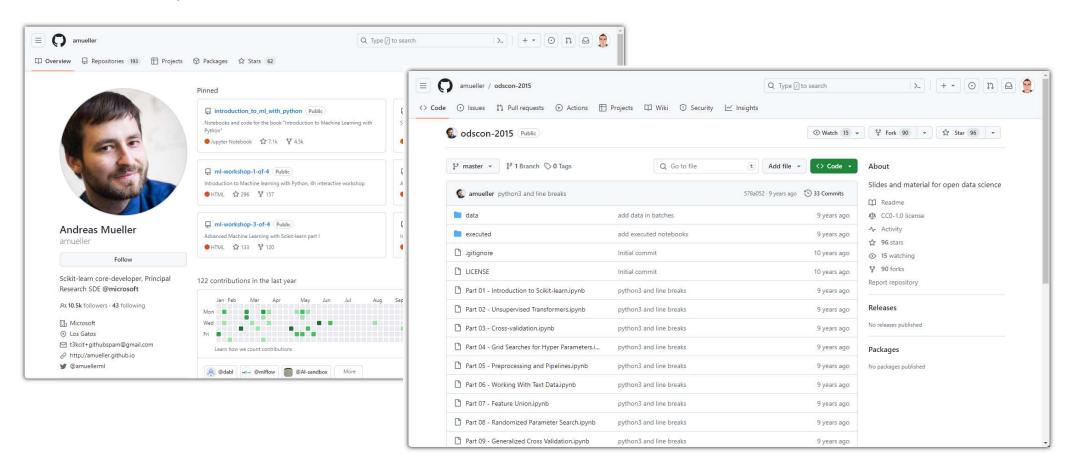
DecisionTreeClassifier is capable of both binary (where the labels are [-1, 1]) classification and multiclass (where the labels are [0, ..., K-1]) classification.

Using the Iris dataset, we can construct a tree as follows:

Toggle Menu

☐ Study

- https://github.com/amueller/odscon-2015
- https://www.youtube.com/watch?v=INFm99ss4Hc&ab_channel=OpenDataScience

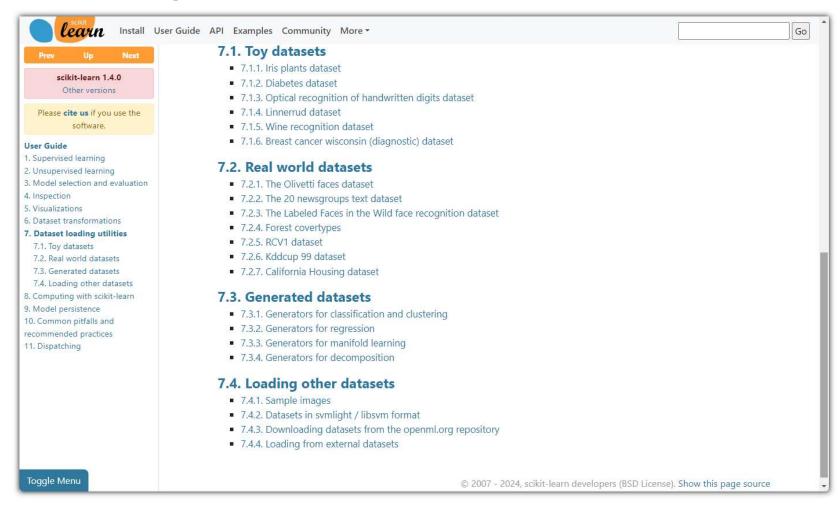


□ scikit-learn 주요 모듈

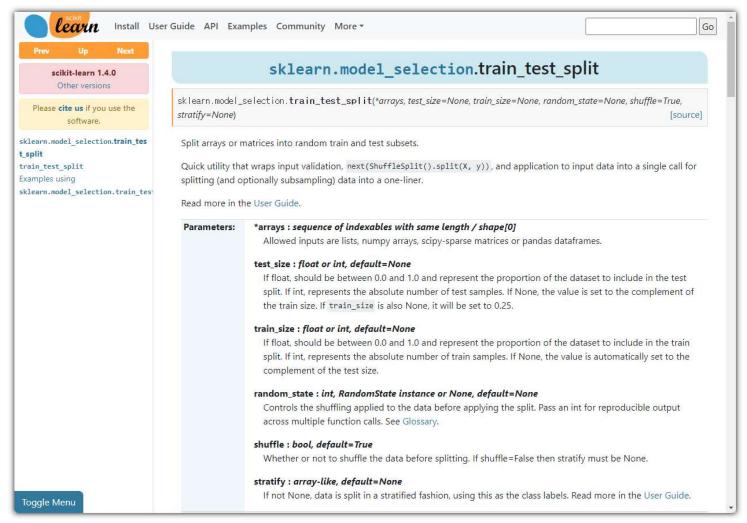
분류	모듈 명	설명
예제 데이터	sklearn.datasets	사이킷런에 내장되어 예제로 제공하는 데이터 세트
피처처리	sklearn.preprocessing	데이터 전처리에 필요한 다양한 가공 기능 제공(문자열을 숫자형 코드 값으로 인코딩, 정규화, 스케일링 등)
	sklearn.feature_selection	알고리즘에 큰 영향을 미치는 피처를 우선순위대로 셀렉션 작업을 수행하는 다양한 기능 제공
	sklearn.feature_extraction	텍스트 데이터나 이미지 데이터의 벡터화된 피처를 추출하는데 사용됨. 예를 들어 텍스트 데이터에서 Count Vectorizer나 Tf-ldf Vectorizer 등을 생성하는 기능 제공. 텍스트 데이터의 피처 추출은 sklearn.feature_extraction.text 모듈에, 이미지 데이터의 피처 추출은 sklearn.feature_extraction.image 모듈에 지원 API가 있음
피처 처리 & 차원 축소	sklearn.decomposition	차원 축소와 관련한 알고리즘을 지원하는 모듈이다. PCA, NMF, Truncated SVD 등을 통해 차원 축소 기능을 수행할 수 있다.
데이터 분리, 검증 & 파라미터 튜닝	sklearn.model_selection	교차 검증을 위한 학습용/테스트용 분리, 그리드 서치(Grid Search)로 최적 파라미터 추출 등의 API 제공
평가	sklearn.metrics	분류, 회귀, 클러스터링, 페어와이즈(Pairwise)에 대한 다양한 성능 측정 방법 제공 Accuracy, Precision, Recall, ROC-AUC, RMSE 등 제공
	sklearn.ensemble	앙상블 알고리즘 제공. 랜덤 포레스트, 에이다 부스트, 그래디언트 부스팅 등을 제공
	sklearn.linear_model	주로 선형 회귀, 릿지(Ridge), 라쏘(Lasso) 및 로지스틱 회귀 등 회귀 관련 알고리즘을 지원. 또한 SGD(Stochastic Gradient Desccent) 관련 알고리즘도 제공
N. 01-7-71-7	sklearn.naïve_bayes	나이브 베이즈 알고리즘 제공. 가우시안 NB. 다항 분포 NB 등
ML 알고리즘	sklearn.neighbors	최근접 이웃 알고리즘 제공. K-NN(K-Nearest Neighborhood) 등
	sklearn.svm	서포트 벡터 머신 알고리즘 제공
	sklearn.tree	의사 결정 트리 알고리즘 제공
	sklearn.cluster	비지도 클러스터링 알고리즘 제공 (K-평균, 계층형, DBSCAN 등)
유틸리티	sklearn.pipeline	피처 처리 등의 변환과 ML 알고리즘 학습, 예측 등을 함께 묶어서 실행할 수 있는 유틸리티 제공

□ 내장된 예제 데이터 세트

- https://scikit-learn.org/stable/datasets.html

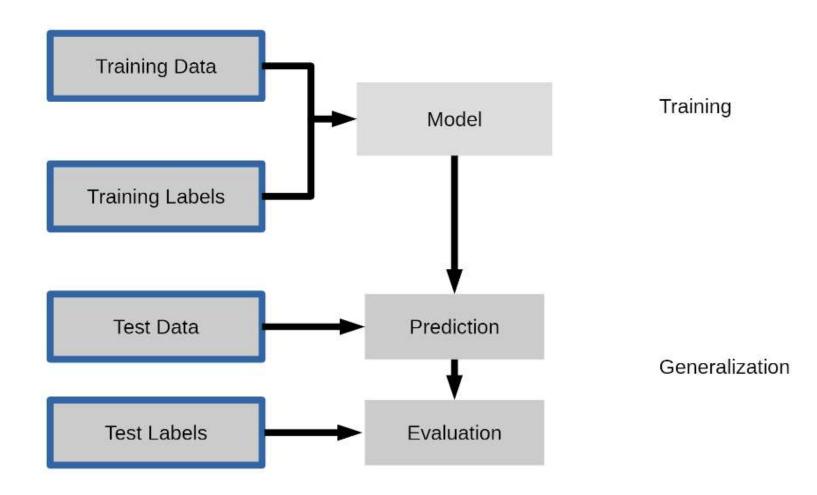


☐ Model Selection



※ 출처: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html#sklearn.model_selection.train_test_split.

☐ Supervised Machine Learning



※ 출처: https://github.com/amueller/odscon-2015

☐ Supervised Machine Learning

clf = RandomForestClassifier()

clf.fit(X_train, y_train)

y_pred = clf.predict(X_test)

clf.score(X_test, y_test)

Training Data

Model

Training Labels

Prediction

Evaluation

※ 출처: https://github.com/amueller/odscon-2015

☐ Basic API of Scikit-Learn

estimator.fit(X, [y])

estimator.predict estimator.transform

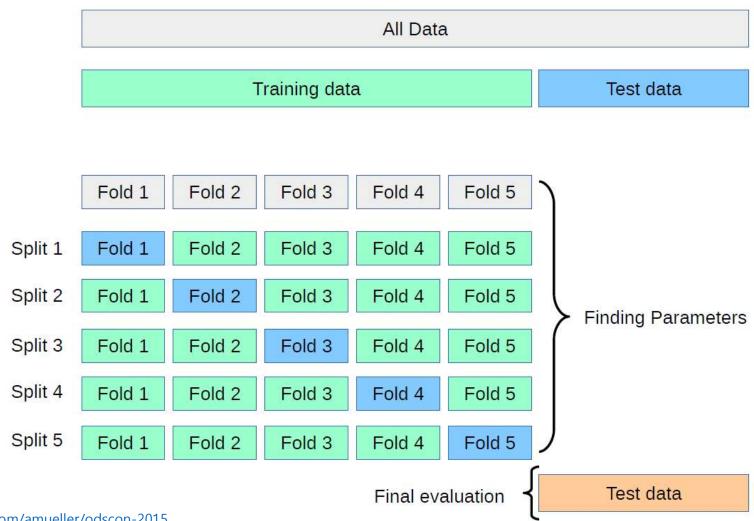
Classification Preprocessing

Regression Dimensionality reduction

Clustering Feature selection

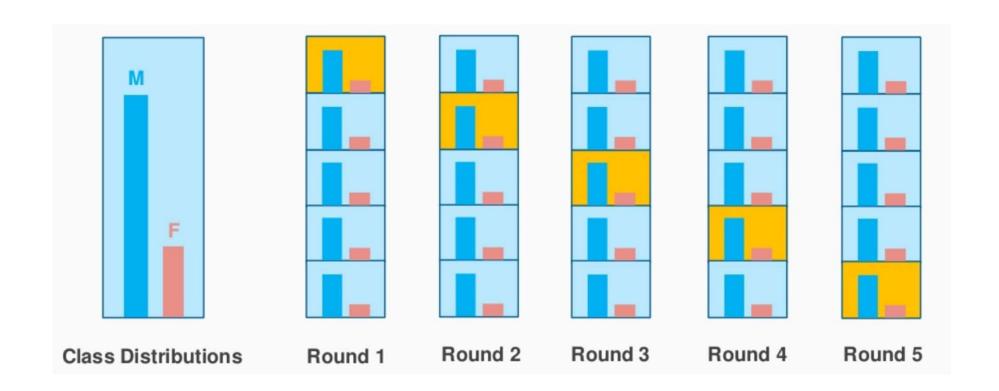
Feature extraction

□ 교차 검증(Cross Validation) : K-Fold



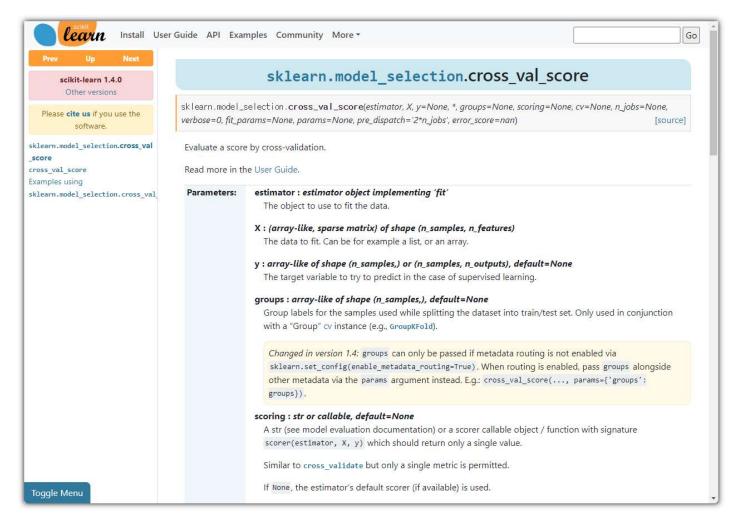
※ 출처: https://github.com/amueller/odscon-2015

□ 교차 검증(Cross Validation) : Stratified K-Fold



※ 출처: https://stats.stackexchange.com/questions/49540/understanding-stratified-cross-validation

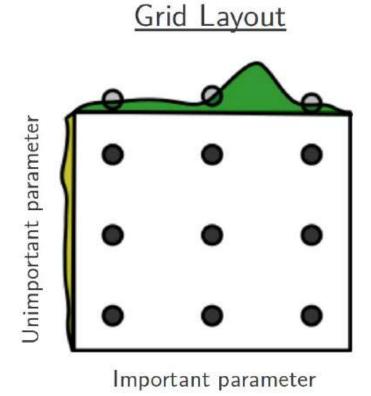
□ 교차 검증(Cross Validation) : cross_val_score()



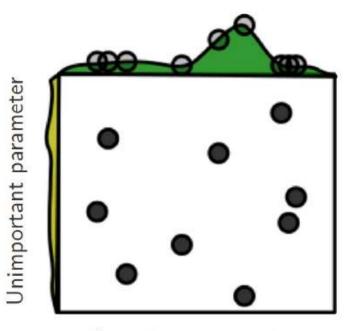
※ 출처: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_score.html

☐ Parameter Search

- Grid vs. Random



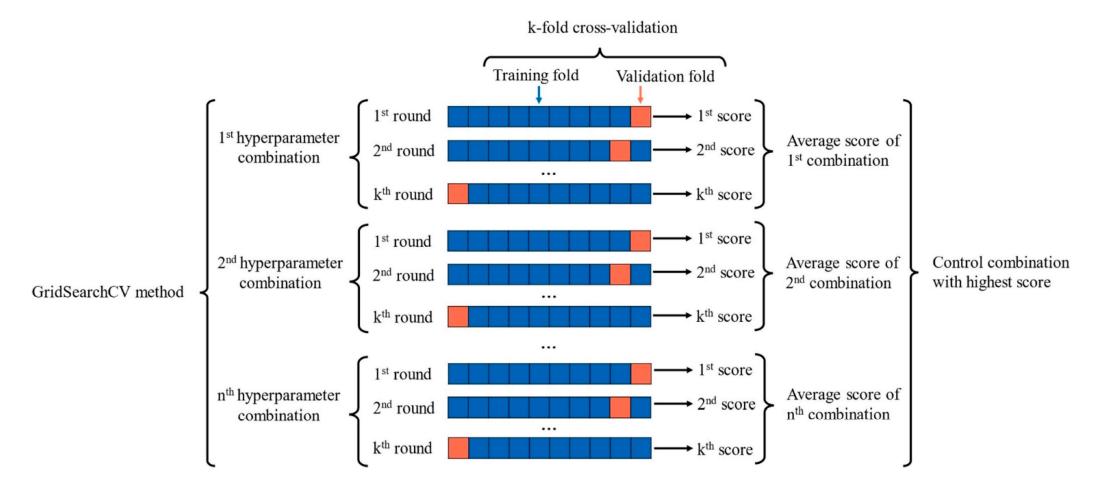
Random Layout



Important parameter

Source: Bergstra and Bengio

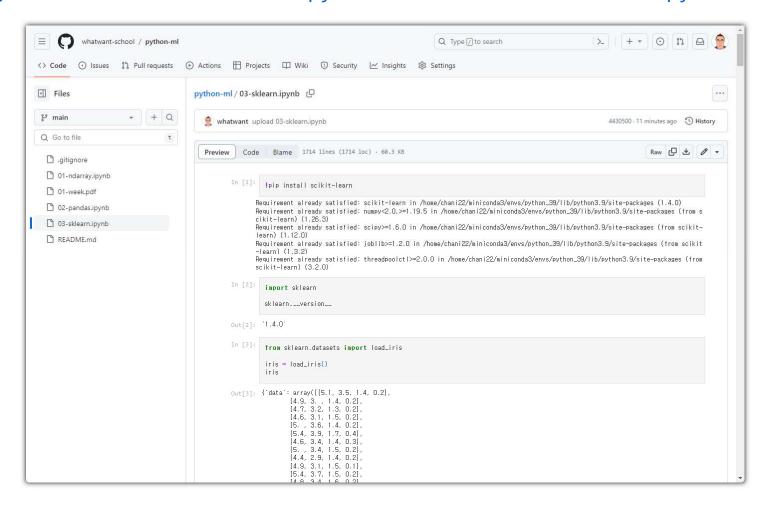
□ 교차 검증(Cross Validation) : GridSearchCV



※ 출처: https://www.mdpi.com/2075-5309/12/5/550

☐ Source Code

- https://github.com/whatwant-school/python-ml/blob/main/03-sklearn.ipynb



You've really worked hard today

Next Week ~?

		목차
	01. 사이킷런 소개와 특징	88
02	02. 첫 번째 머신러닝 만들어 보기 - 붓꽃 품종 예측하기	.88
사이킷런으로 시작하는	03. 사이킷런의 기반 프레임워크 익히기	91
머신러닝	Estimator 이해 및 filf(), predict() 메셔드	9
	사이킷런의 주요 모듈	9:
	내장된 예제 데이터 세트	9
	04. Model Selection 모듈 소개	91
	학습/테스트 데이터 세트 분리 - train_test_split()	91
	교차 검증	1.00
	GridSearchCV – 교차 검증과 최적 하이퍼 파라미터 튜닝을 한	반에 11
	05. 데이터 전처리	116
	데이터 인코딩	118
	피처 스케일링과 정규화	12
	StandardScaler	12
	MinMaxScaler	12
	학습 데이터와 테스트 데이터의 스케일링 변환 시 유의점	12
	06. 사이킷런으로 수행하는 타이타닉 생존자 예측	129
	07. 정리	143
00	01. 정확도(Accuracy)	14
03	02. 오차 행렬	150
평가	03. 정밀도와 재현율	154
22	정밀도/재현율 트레이드오프	157
	정밀도와 재취율의 명점	168

X SA		

	04, F1 스코어	186
	05. ROC 곡선과 AUC	167
	0.6, 피마 인디언 당뇨병 예측	172
	07. 정리	180
	01. 분류(Classification)의 개요	181
04	02. 결정 트리	183
 早	결정 트리 모델의 특징	185
产 种	결정 트리 파라미터	186
	결정 트리 모델의 시각화	187
	결정 트리 과적합(Overlitting)	198
	결정 트리 싫습 - 사용자 행동 인식 데이터 세트	200
	03. 앙상불 학습	210
	명상불 학습 개요	210
	보팅 유형 - 하드 보팅(Hard Voting)과 소프트 보팅(Soft Voting)	212
	보딤 분류기(Voting Classifier)	213
	04. 랜덤 포레스트	216
	랜덤 포레스트의 개요 및 실습	216
	랜덤 포레스트 하이퍼 파라미터 및 튜닝	218
	GBM의 개요 및 실습	221
	05. GBM(Gradient Boosting Machine)	221
	GBM 하이퍼 파라미터 소개	224
	XGBoost 76Ω	225

Who ~?

See you Next Weekend ~?